



Máster Universitario en Inteligencia Artificial

2025-2026

MLOPs

Lab 3

Pregunta 1

Si borrraras la carpeta models y reiniciaras el servidor, obtendrías exactamente el mismo modelo con el mismo accuracy debido a que el proceso de entrenamiento inicial o Bootstrap es totalmente determinista. La reproducibilidad está garantizada por el uso del parámetro `random_state=42`, el cual se encuentra configurado tanto en la función `train_test_split` para asegurar que la división entre datos de entrenamiento y prueba sea siempre la misma, como en la instancia de `LogisticRegression` para que el algoritmo de optimización converja siempre a los mismos pesos. Al fijar esta semilla aleatoria en las líneas de código mencionadas, el sistema garantiza que el modelo resultante y su métrica de calidad (0.9667) sean idénticos en cada ejecución, independientemente de cuántas veces se resetee el entorno.

Pregunta 2

Si enviaras 10 muestras perfectamente etiquetadas pero todas pertenecientes a la clase setosa, el modelo no se entrenaría ni se activaría, ya que la API interrumpiría el proceso devolviendo un error 422. Siguiendo el flujo lógico del endpoint `/train`, tras preparar las muestras, el sistema ejecuta una validación mediante la función `np.unique(y_train)` para contar cuántas categorías diferentes existen en el conjunto de datos. Al detectar solo una clase, se lanza una excepción de forma inmediata que impide llegar a la fase de ajuste del modelo (`clf_new.fit`). Esta restricción es fundamental desde un punto de vista de Machine Learning, ya que un algoritmo de clasificación supervisada como la Regresión Logística necesita, como mínimo, dos clases para poder calcular una frontera de decisión; sin ejemplos de contraste, el modelo no tendría ninguna base matemática para aprender a diferenciar una categoría de otra, careciendo de utilidad práctica.

Pregunta 3

El diseño de registrar los modelos rechazados en el historial es una pieza clave para la auditoría y la observabilidad dentro de un ciclo de MLOps. Esta práctica permite rastrear no solo los éxitos, sino también los intentos fallidos, lo que resulta fundamental para identificar qué conjuntos de datos específicos están degradando el rendimiento o introduciendo ruido en el sistema. Si solo guardáramos los modelos activados, perderíamos información valiosa sobre la calidad de las nuevas muestras y no tendríamos evidencia técnica de por qué se tomó la decisión de rechazar una versión concreta. En resumen, este registro completo funciona como una bitácora de depuración que ayuda a los ingenieros a entender el comportamiento del modelo frente a datos reales y a detectar posibles problemas en la ingesta de datos antes de que estos puedan comprometer la estabilidad del servicio en el futuro.

Pregunta 4

Mantener la regla del mayor o igual es generalmente la opción más acertada en entornos de producción, ya que permite la actualización del modelo incluso cuando la métrica de calidad se ha estabilizado cerca de su máximo. Aunque el accuracy sea idéntico, un modelo entrenado con un dataset más extenso y reciente suele ser más robusto y capaz de generalizar mejor ante casos de borde que un modelo antiguo, aunque dicha mejora no se refleje en un incremento porcentual de la métrica principal. Si se utilizara un mayor estricto (`>`), el sistema correría el riesgo de quedar "estancado" con una versión obsoleta, ignorando datos nuevos de alta calidad simplemente porque no aportan una mejora estadística inmediata, lo que a la larga afectaría a la frescura y relevancia del servicio frente a cambios sutiles en los datos de entrada.

Github: <https://github.com/victortomemo/MLOPs-VTG>