



Máster Universitario en Inteligencia Artificial

2025-2026

MLOPs

Lab 4

Tabla de parámetros y métricas de los modelos que hayas decidido incluir en el registro, especificando la razón de por qué es útil registrar estos y no los de otros runs que hayas realizado

Modelo	Solver	C	Accuracy	F1-Score	Recall	Precision
crawling-turtle-604	lbfgs	0.01	0.7922	0.6734	0.5593	0.8461
fun-snipe-735	lbfgs	0.1	0.7922	0.6734	0.5593	0.8461

El criterio principal de selección se ha fundamentado en el ámbito médico del problema. En este contexto, el coste de un Falso Negativo es mucho más grave que un Falso Positivo. Por consiguiente, la métrica prioritaria a maximizar ha sido el Recall.

Al analizar los resultados del Grid Search, los modelos crawling-turtle-604 y fun-snipe-735 obtuvieron las mismas métricas en el conjunto de validación, destacando por poseer el Recall más alto de la iteración. Para el desempate y registro final en MLflow, se aplicó un criterio técnico de Machine Learning: la penalización por regularización. Se seleccionó el modelo con $C=0.01$ frente al de $C=0.1$ porque un valor menor de C implica una regularización más estricta. Esto genera un modelo más conservador y menos propenso a overfitting, garantizando teóricamente una mejor generalización ante futuros pacientes.

Conclusiones

- **Gobernanza del Ciclo de Vida:** Al registrar el modelo, se gestiona como un activo de software con control de versiones, lo que permite realizar actualizaciones o rollbacks seguros sin interrumpir el servicio.
- **Robustez e Integridad de Datos:** Gracias al uso de firmas en MLflow, el modelo no solo guarda el algoritmo, sino también las reglas de los datos que espera recibir. Esto es vital en la puesta en producción, pues actúa como un filtro de seguridad que rechaza datos corruptos o incompletos, asegurando que el sistema solo procese información válida y evitando así fallos silenciosos.
- **Despliegue y Desacoplamiento:** Una de las mayores ventajas de la puesta en producción es el uso de peticiones HTTP. Al convertir nuestro modelo en un servicio web, hablamos un idioma universal que cualquier software entiende. Esto permite que el modelo de predicción de diabetes sea una pieza intercambiable y fácil de integrar en sistemas de salud reales sin complicaciones técnicas.